

LAPORAN MACHINE LEARNING
Prediksi Risiko Keterlambatan Pengiriman Paket (*Late Delivery Risk*) Pada Dataset *DataCo Supply Chain* Dengan Algoritma Logistic Regression, Random Forest dan XGBoost

Disusun untuk Memenuhi Tugas UAS Mata Kuliah Machine Learning

Dosen Pengampu:

Eliyani, Dr. Ir., M.Kom.



Disusun Oleh:

Lisa Damayanti (41524010002)

**PROGRAM STUDI S1 TEKNIK INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS MERCU BUANA
TAHUN 2025/2026**

DAFTAR ISI

BAB I DESKRIPSI DATASET, TUJUAN, DAN EDA.....	4
1.1 Latar Belakang.....	4
1.2 Deskripsi Dataset.....	4
1.2.1 Alasan Pemilihan Dataset.....	7
1.2.2 Alasan Pemilihan Target.....	7
1.3 Tujuan.....	8
1.4 Jenis Machine Learning.....	8
1.5 Exploratory Data Analysis (EDA).....	8
1.5.1 Distribusi Target.....	8
1.5.2 Distribusi Fitur Numerik.....	10
1.5.3 Deteksi Outlier.....	10
1.5.4 Distribusi Fitur Kategorikal.....	11
1.5.5 Distribusi Hubungan Fitur dengan Target.....	11
1.5.5 Korelasi Fitur Numerik terhadap Target.....	13
1.6 Data Preprocessing.....	13
1.6.1 Penanganan Missing Value.....	14
1.6.2 Menghapus Data Duplikat dan Menghapus Fitur yang Tidak Perlu digunakan & yang Berisiko Leakage.....	14
1.6.3 Encoding.....	15
1.6.4 Feature Engineering.....	15
1.6.6 Standarisasi / Normalisasi.....	15
1.6.7 Train-Test Split.....	15
1.7 Penelitian Terdahulu.....	16
BAB II PEMBANGUNAN MODEL.....	17
2.1 Algoritma Logistic Regression.....	17
2.2 Algoritma Random Forest.....	18
2.3 Algoritma XGboost.....	20
2.4 ROC-AUC Curve, Precision-Recall Curve, Learning Curve dan, Validation Curve....	21
2.4.1 ROC-AUC Curve.....	21
2.4.2 Precision-Recall Curve.....	21
2.4.3 Learning Curve.....	22
2.4.3 Validation Curve.....	22
BAB III ANALISIS DAN PENINGKATAN MODEL.....	23
3.1 Teknik Peningkatan Model.....	23
3.1.1 Hyperparamater Tuning.....	23
Alasan Saya Menjadikan Model Tuning sebagai Model Final.....	23
3.1.2 Feature Selection.....	24
3.1.3 SMOTE (Synthetic Minority Oversampling Technique).....	25
3.3 Ensemble (Voting Classifier).....	25
3.4 Cross Validation (Stratified K-Fold).....	26
3.3 Feature Importance.....	26
3.3.1 Feature Importance Logistic Regression.....	26
3.3.2 Feature Importance Random Forest.....	27

3.3.3 Feature Importance XGBoost.....	27
3.3 Perbandingan Performa Model.....	27
BAB IV PEMBAHASAN DAN KESIMPULAN.....	29
4.1 Interpretasi Model.....	29
4.2 Algoritma Terbaik.....	29
4.3 Kekuatan dan Kelemahan Model.....	29
4.3.1 Kekuatan Model.....	29
4.3.2 Kelemahan Model.....	29
4.4 Rekomendasi Implementasi.....	30
4.5 Kesimpulan.....	30
DAFTAR PUSTAKA.....	31

BAB I

DESKRIPSI DATASET, TUJUAN, DAN EDA

1.1 Latar Belakang

Perkembangan e-commerce telah meningkatkan aktivitas pengiriman barang dalam beberapa tahun terakhir. Bagi pelanggan, ketepatan waktu pengiriman merupakan salah satu aspek penting yang memengaruhi kepuasan terhadap layanan jasa logistik. Keterlambatan pengiriman dapat menimbulkan ketidakpuasan pelanggan, mengurangi kepercayaan terhadap perusahaan, serta berdampak pada operasional dan reputasi bisnis.

Dalam kehidupan sehari-hari, pelanggan sering kali menunggu kedatangan paket sesuai estimasi yang diberikan. Namun, tidak semua pengiriman tepat waktu. Berbagai faktor, seperti kondisi operasional, wilayah pengiriman, layanan pengiriman, metode pembayaran dll dapat memengaruhi keterlambatan. Oleh karena itu, perusahaan perlu memiliki kemampuan untuk mengidentifikasi sejak dini pesanan yang berpotensi mengalami keterlambatan agar dapat melakukan langkah antisipasi

Salah satu pendekatan yang dapat digunakan untuk mengatasi permasalahan tersebut adalah machine learning. Dengan memanfaatkan data historis pengiriman, machine learning mampu mempelajari pola yang memengaruhi keterlambatan pada pesanan baru. Beberapa penelitian sebelumnya juga telah membangun model klasifikasi dengan menerapkan algoritma seperti Logistic Regression, Random Forest, dan XGBoost pada dataset DataCo Smart Supply Chain untuk memprediksi keterlambatan pengiriman. Selain itu penelitian ini juga ingin membandingkan performa ketiga algoritma.

1.2 Deskripsi Dataset

Dataset yang saya pilih ini adalah DataCo Smart Supply Chain yang berasal dari repositori Mendeley. Dataset ini mengenai publik operasional rantai pasok milik perusahaan DataCo Global yang berisi transaksi pemesanan, pengiriman, pelanggan, dan produk dari tahun 2015-2018. Jumlah dataset ini berisi 180.519 baris dengan 53 fitur, namun penelitian ini menggunakan 40.000 data hasil stratified random sampling untuk menyesuaikan kebutuhan komputasi selama proses pemodelan.

No	Nama Fitur	Tipe Data	Keterangan
1	Type	Object	Jenis transaksi atau metode pembayaran yang digunakan pelanggan.
2	Days for shipping (real)	Integer	Jumlah hari aktual yang dibutuhkan hingga pesanan diterima pelanggan.
3	Days for shipment (scheduled)	Integer	Jumlah hari pengiriman yang dijadwalkan oleh perusahaan.

4	Benefit per order	Float	Keuntungan atau kerugian yang diperoleh perusahaan dari setiap pesanan.
5	Sales per customer	Float	Total nilai penjualan yang dihasilkan dari setiap pelanggan.
6	Late_delivery_risk	Integer	Status risiko keterlambatan pengiriman (0 = Tidak Terlambat, 1 = Terlambat).
7	Category Id	Integer	ID unik kategori produk.
8	Category Name	Object	Nama kategori produk yang dipesan pelanggan.
9	Customer City	Object	Kota tempat pelanggan berada.
10	Customer Country	Object	Negara tempat pelanggan berada.
11	Customer Email	Object	Alamat email pelanggan.
12	Customer Fname	Object	Nama depan pelanggan.
13	Customer Id	Integer	ID unik pelanggan.
14	Customer Lname	Object	Nama belakang pelanggan.
15	Customer Password	Object	Password akun pelanggan dalam bentuk terenkripsi.
16	Customer Segment	Object	Segmen pelanggan, seperti Consumer, Corporate, atau Home Office.
17	Customer State	Object	Negara bagian atau provinsi tempat pelanggan berada.
18	Customer Street	Object	Alamat jalan pelanggan.
19	Customer Zipcode	Float	Kode pos pelanggan.
20	Department Id	Integer	ID unik departemen produk.
21	Department Name	Object	Nama departemen tempat produk berada.
22	Latitude	Float	Koordinat lintang (latitude) lokasi pelanggan.
23	Longitude	Float	Koordinat bujur (longitude) lokasi pelanggan.

24	Market	Object	Wilayah pasar tempat transaksi dilakukan, misalnya Europe, Asia Pacific, Latin America, dan lain-lain.
25	Order City	Object	Kota tujuan pengiriman pesanan.
26	Order Country	Object	Negara tujuan pengiriman pesanan.
27	Order Customer Id	Integer	ID pelanggan yang melakukan pemesanan.
28	Order Date (DateOrders)	Datetime	Tanggal dan waktu pesanan dibuat.
29	Order Id	Integer	ID unik setiap pesanan.
30	Order Item Cardprod Id	Integer	ID produk pada item pesanan.
31	Order Item Discount	Float	Nilai diskon yang diberikan pada item pesanan.
32	Order Item Discount Rate	Float	Persentase diskon yang diberikan pada item pesanan.
33	Order Item Id	Integer	ID unik setiap item dalam pesanan.
34	Order Item Product Price	Float	Harga produk pada item pesanan sebelum diskon.
35	Order Item Profit Ratio	Float	Rasio keuntungan yang diperoleh dari item pesanan.
36	Order Item Quantity	Integer	Jumlah unit produk yang dipesan.
37	Sales	Float	Total nilai penjualan dari pesanan.
38	Order Item Total	Float	Total harga item pesanan setelah memperhitungkan diskon.
39	Order Profit Per Order	Float	Total keuntungan yang diperoleh dari setiap pesanan.
40	Order Region	Object	Wilayah geografis tujuan pengiriman pesanan.
41	Order State	Object	Negara bagian atau provinsi tujuan pengiriman.
42	Order Status	Object	Status pesanan, seperti COMPLETE, PENDING, PROCESSING, CLOSED, atau SUSPECTED_FRAUD.

43	Product Card Id	Integer	ID unik kartu produk.
44	Product Category Id	Integer	ID kategori produk.
45	Product Description	Object	Deskripsi atau informasi mengenai produk.
46	Product Image	Object	URL atau lokasi gambar produk.
47	Product Name	Object	Nama produk yang dijual.
48	Product Price	Float	Harga asli produk.
49	Product Status	Integer	Status produk (0 = tidak aktif, 1 = aktif).
50	Shipping Mode	Object	Metode pengiriman yang digunakan, seperti Standard Class, First Class, Second Class, atau Same Day.
51	Order Zipcode	Float	Kode pos tujuan pengiriman pesanan.
52	Delivery Status	Object	Status akhir proses pengiriman, seperti Advance Shipping, Late Delivery, Shipping Cancelled, atau Shipping on Time.
53	Customer Full Name	Object	Nama lengkap pelanggan yang merupakan gabungan nama depan dan nama belakang pelanggan.

Sumber Dataset: <https://data.mendeley.com/datasets/8gx2fvg2k6/5>

1.2.1 Alasan Pemilihan Dataset

Dataset ini dipilih karena merepresentasikan permasalahan yang nyata pada bidang *Supply Chain Management (SCM)*, khususnya dalam operasional logistik dan distribusi barang di perusahaan ritel. Database ini memuat informasi mengenai pelanggan, produk, transaksi penjualan, pesanan, serta proses pengiriman, sehingga dapat digunakan untuk menganalisis berbagai faktor yang memengaruhi risiko keterlambatan pengiriman. Sehingga memiliki karakteristik yang sesuai untuk membangun model machine learning dalam memprediksi keterlambatan pengiriman.

1.2.2 Alasan Pemilihan Target

Target `Late_delivery_risk` dipilih karena secara langsung merepresentasikan permasalahan yang ingin diselesaikan dalam penelitian ini, yaitu memprediksi apakah suatu pesanan mengalami keterlambatan pengiriman pesanan. Prediksi ini penting agar perusahaan dapat mengambil langkah antisipasi sejak awal, seperti memberikan estimasi waktu pengiriman yang lebih akurat, menentukan layanan pengiriman yang sesuai dan mengoptimalkan proses distribusi.

1.3 Tujuan

Tujuan dilakukan penelitian ini adalah untuk:

1. Membangun model prediktif yang dapat mengklasifikasikan sebuah pesanan ke dalam kategori yang berisiko terlambat atau tidak terlambat berdasarkan fitur-fitur.
2. Mengidentifikasi variabel-variabel yang paling berpengaruh terhadap risiko keterlambatan pengiriman sebagai dasar rekomendasi bisnis.
3. Membandingkan performa algoritma klasifikasi, seperti Logistic Regression, Random Forest, dan XGBoost.

1.4 Jenis Machine Learning


Pada penelitian permasalahan ini masuk ke dalam kategori klasifikasi biner, karena target yang digunakan bersifat kategorikal dengan 2 kelas (0 = Tidak Terlambat, 1= Terlambat). Penelitian ini juga termasuk kategori supervised learning karena sudah memiliki target.

1.5 Exploratory Data Analysis (EDA)


Exploratory Data Analysis (EDA) dilakukan untuk memahami karakteristik DataCo Smart Supply Chain Dataset sebelum membangun model machine learning. Pada tahap ini dilakukan analisis terhadap distribusi target `Late_delivery_risk`, distribusi fitur numerik dan kategorikal, deteksi missing value, data duplikat, outlier, serta korelasi antar fitur. Hasil analisis ini digunakan sebagai dasar dalam menentukan tahapan preprocessing, seperti penanganan missing value, penghapusan fitur yang tidak relevan atau berpotensi menyebabkan *data leakage*, proses encoding, dan feature selection sebelum model dibangun.

1.5.1 Distribusi Target


Distribusi kelas target `Late_delivery_risk` menunjukkan 81.542 (45,17%) 0 = data tidak terlambat dan 98.977 (54,83%) 1 = data terlambat. Kondisi ini menunjukkan sedikit ketidakseimbangan kelas yang trelatif kecil sehingga distribusi data masih tergolong cukup seimbang..



Distribusi kelas target `Late_delivery_risk` setelah dilakukan sampling $n=40000$ menunjukkan 18.068 (45,17%%) 0 = data tidak terlambat dan 21.932 (45,83%) 1 = data terlambat. Kondisi ini menunjukkan sedikit ketidakseimbangan kelas yang relatif kecil sehingga distribusi data masih tergolong cukup seimbang.




1.5.2 Distribusi Fitur Numerik



Berdasarkan histogram diatas, sebagian besar fitur numerik memiliki distribusi yang tidak merata dan cenderung condong ke kanan (*right-skewed*). Dilihat pada fitur Sales data menumpuk di rentang (0-400), Order Item Product Price di rentang (0-400) artinya pelanggan banyak membeli produk di rentang harga <500 , dan Product Price di rentang (0-400) yang dimana mayoritas transaksi berada pada nilai relatif rendah. Fitur Benefit per Order menunjukkan distribusi yang tidak merata yang dimana memiliki sebaran nilai negatif hingga positif, yang menunjukkan adanya keuntungan dan kerugian. Sementara itu, Order Item Quantity paling banyak dibeli sebanyak 1 unit. Kemudian ada fitur Days for Shipping (real) dimana sebagian besar pengiriman diselesaikan dalam waktu 2-6 hari.


1.5.3 Deteksi Outlier



Berdasarkan boxplot, beberapa fitur numerik seperti Benefit per Order, Sales per Customer, Order Item Discount, Order Item Product Price, Product Price, dan Sales memiliki

banyak titik yang berada di luar batas whisker, yang menunjukkan adanya outlier. Ini menunjukkan bahwa ada beberapa transaksi yang memiliki nilai jauh lebih tinggi atau lebih rendah dibandingkan kebanyakan data. Dalam Benefit per Order, terdapat nilai-nilai ekstrem baik yang bernilai negatif maupun positif, yang menunjukkan adanya transaksi yang mengalami kerugian atau keuntungan yang sangat besar. Sementara itu, beberapa nilai ekstrem juga ditemukan pada Sales, Harga Produk, Harga Produk dalam Item Pesanan, Penjualan per Pelanggan, dan Diskon dalam Item Pesanan, yang kemungkinan besar berasal dari transaksi dengan harga, jumlah penjualan, atau besaran diskon yang jauh lebih tinggi dibandingkan transaksi biasa. Sebaliknya, fitur Order Item Quantity, Days for Shipping (real), dan Days for Shipment (scheduled) tidak menunjukkan nilai-nilai yang tidak biasa karena ketigafitur tersebut memiliki rentang nilai yang tidak terlalu lebar dan bersifat diskrit. Secara umum, adanya nilai ekstrem pada beberapa variabel keuangan adalah hal yang biasa dalam data transaksi dan tetap dilewatkan karena masih mencerminkan kondisi sebenarnya serta bisa memberikan informasi penting bagi model prediksi.

1.5.4 Distribusi Fitur Kategorikal



Berdasarkan histogram pada fitur kategorikal, pada fitur Shipping Mode, pelanggan banyak menggunakan jasa layanan standard class untuk mengirimkan paket mereka. Kemudian di Market penyebaran wilayah pemesanan paket yang paling banyak ada di Latin America dan Europe. Sedangkan pada fitur kategori yang paling sering dibeli adalah Cleats dan ,Men's Footwear.


1.5.5 Distribusi Hubungan Fitur dengan Target



Pada hasil analisis hubungan fitur distribusi grafik diatas terhadap target menunjukkan bahwa Shipping Mode dan Days for Shipment (scheduled) adalah 2 faktor yang paling berpengaruh terhadap Late_delivery_risk, sedangkan faktor lain relatif tidak berpengaruh. Shipping Mode / mode pengiriman, seperti First Class dan Second Class justru punya tingkat keterlambatan tinggi (95,3% dan 76,6%) dibanding Same Day dan Standard Class (45,7% dan 38,1%), mengindikasikan masih adanya masalah ketidaksi- konsistenan dalam pelayanan. Faktor wilayah hampir tidak berpengaruh pada keterlambatan pengiriman.

Dari sisi kategori produk, Golf Bags & Carts memiliki tingkat tertinggi (68,9%) mungkin karena produknya berukuran besar. Kemudian secara korelasi, hanya Days for Shipment (real) (+0,40) dan Days for Shipment (scheduled) (-0,37) yang punya hubungan cukup kuat dengan target. Nantinya fitur Days for Shipment (real) ini akan di hapus karena akan menyebabkan *data leakage*. sedangkan jadwal pengiriman yang dijadwalkan lebih singkat 2 hari pada pesanan justru malah terlambat, dibanding yang dijadwalkan 4 hari justru lebih tepat waktu. Sementara itu, secara tren waktu, tingkat keterlambatan relatif stabil di kisaran 54-57% sepanjang 2015-2018 tanpa pola musiman yang jelas, kecuali satu anomali penurunan tajam ke $\pm 51,9\%$ pada pertengahan 2016.

1.5.5 Korelasi Fitur Numerik terhadap Target



Heatmap korelasi awal menunjukkan bahwa Days for shipping (real) (+0,40) dan Days for shipment (scheduled) (-0,37) memiliki korelasi tertinggi terhadap Late_delivery_risk dibandingkan fitur finansial lain seperti Sales, Benefit per order, atau Order Item Quantity yang cenderung berkorelasi lemah terhadap target.

1.6 Data Preprocessing

Dilakukan untuk membersihkan data yang kosong, duplikat, encoding (mengubah fitur kategori menjadi numerik), feature engineering, feature selection, standarisasi/normalisasi (untuk Logistic Regression), train-test split dan penyeimbang kelas menggunakan SMOTE pada data latih.

1.6.1 Penanganan Missing Value

	Jumlah Missing	Persentase (%)
Customer Lname	8	0.00
Customer Zipcode	3	0.00
Order Zipcode	155679	86.24
Product Description	180519	100.00

- Customer Lname, tidak dihapus karena missing nya sedikit hanya 8% dan diisi dengan modus (nama yang sering muncul) nama belakang pelanggan, yaitu smith.
- Customer Zipcode, tidak dihapus karena missing nya sedikit hanya 8% dan diisi dengan modus kode pos (kode pos yang sering muncul), yaitu 725.0
- Order Zipcode, dihapus karena missing valuenya 86,24% sehingga tidak layak diimputasi dan berpotensi menurunkan kualitas model jika dipertahankan.
- Product Description, dihapus karena missing valuenya 100% dan fitur ini tidak memberikan informasi apapun hanya berupa deskripsi produk.

1.6.2 Menghapus Data Duplikat dan Menghapus Fitur yang Tidak Perlu digunakan & yang Berisiko Leakage

Pada dataset ini pengecekan baris duplikat menghasilkan 0 baris data duplikat, sehingga pada tahap ini tidak ada yang perlu dihapus.

```
duplicates = df.duplicated().sum()
print(f"Jumlah data duplikat sebelum dihapus: {duplicates}")

df = df.drop_duplicates().reset_index(drop=True)

print(f"Jumlah data duplikat setelah dihapus: {df.duplicated().sum()}")
print("Shape df setelah hapus duplikat:", df.shape)

Jumlah data duplikat sebelum dihapus: 0
Jumlah data duplikat setelah dihapus: 0
Shape df setelah hapus duplikat: (180519, 51)
```

```
df.drop(columns=[
    'Customer Email',
    'Customer Password',
    'Customer Fname',
    'Customer Lname',
    'Customer Street',
    'Customer Id',
    'Order Customer Id',
    'Order Id',
    'Order Item Id',
    'Order Item Cardprod Id',
    'Product Card Id',
    'Product Image',
    'Product Status',
    'Category Id',
    'Department Id',
    'Product Price',
    'Order Profit Per Order',
    'order date (DateOrders)',
    'shipping date (DateOrders)',
    'Days for shipping (real)',
    'Delivery Status',
], inplace=True)

print(f"Jumlah kolom setelah preprocessing: {df.shape[1]}")
df.info()
```

Penghapusan fitur identitas, seperti Customer Id, Order Id, Product Card Id dll dilakukan agar model hanya menggunakan fitur yang relevan. Fitur Days for Shipping (real)

dan Delivery Status dihapus untuk mencegah data leakage karena kedua fitur tersebut berisi jumlah hari yang dibutuhkan agar paket sampai. Jika fitur yang menyebabkan leakage itu tidak dihapus dikhawatirkan model dapat mencontek melalui fitur tersebut.

1.6.3 Encoding

Proses ini adalah mengubah fitur kategorikal ke dalam numerik. Proses ini dilakukan karena machine learning hanya mampu mengenali numerik, prosesnya dilakukan menggunakan label encoders (Algoritma Random Forest dan XGBoost), sedangkan pada Logistic Regression dilakukan standarisasi menggunakan standard scaler terpisah agar mengurangi bias.

1.6.4 Feature Engineering

Feature engineering dilakukan untuk membuat fitur baru yang lebih informatif dari fitur yang sudah ada sebelumnya. Terdapat 2 fitur baru, yaitu Total_Item_Value (order item product price x order item quantity) dan High_Discount_Flag yang masing-masing fitur tujuannya untuk mengetahui total nilai transaksi pada setiap item order, sehingga memberikan informasi apakah suatu order mendapat diskon tinggi atau tidak. Misal harga 1 nya = 300rb x 2 = 600rb. Lalu dari total item value dilihat apakah akan mendapat diskon tinggi.

Fitur baru berhasil dibuat: 'Total_Item_Value' dan 'High_Discount_Flag'

	Order Item Product Price	Order Item Quantity	Total_Item_Value	Order Item Discount Rate	High_Discount_Flag
0	327.75	1	327.75	0.04	0
1	327.75	1	327.75	0.05	0
2	327.75	1	327.75	0.06	0
3	327.75	1	327.75	0.07	0
4	327.75	1	327.75	0.09	0

1.6.6 Standarisasi / Normalisasi

Standarisasi hanya dilakukan pada algoritma Logistic Regression dengan menggunakan StandardScaler karena algoritma ini sensitif pada skala fitur agar model tidak dipengaruhi oleh fitur yang nilainya jauh lebih besar..

```
scaler = StandardScaler()

X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

✓ 0.0s

1.6.7 Train-Test Split

Dikarenakan keterbatasan komputasi, saya menggunakan data sample sebanyak 40.000 dari keseluruhan jumlah data yaitu, 180.519 baris dengan mempertahankan proporsi

kelas target. Data dibagi menjadi data latih dan data uji dengan rasio 80:20 secara stratified agar proporsi kelas pada data latih dan uji konsisten.

1.7 Penelitian Terdahulu

Beberapa penelitian sebelumnya telah menerapkan machine learning untuk memprediksi keterlambatan atau status pengiriman barang pada supply chain. Apnena dkk. (2025) membandingkan lima algoritma (Logistic Regression, Random Forest, SVM, KNN, XGBoost), dengan XGBoost untuk memprediksi Delivery Status. Mencatatkan akurasi tertinggi (99,97% setelah oversampling), diikuti Random Forest (99,95%), sementara Logistic Regression jauh tertinggal (78,53%). Pambudi dkk. (2020) menguji model regresi logistik dan Random Forest untuk memprediksi tahapan proses transportasi pengiriman, dengan regresi logistik mencapai rata-rata akurasi 76,81% pada tahap Incoming Transport. Sementara itu, Eriya dkk. (2026) membandingkan beberapa model machine learning berbasis framework BADIR untuk mendeteksi fraud sekaligus memprediksi keterlambatan pengiriman pada supply chain.

Gunawan dkk. (2025) menerapkan K-Nearest Neighbors, Random Forest, dan Logistic Regression untuk mengklasifikasikan kinerja pengiriman logistik berdasarkan prediksi ETA, dengan Logistic Regression memperoleh akurasi tertinggi sebesar 99,76%, diikuti Random Forest 98,55% dan K-Nearest Neighbors 93,12%. Selain itu, Sultana dkk. (2025) membandingkan Logistic Regression, Decision Tree, Random Forest, XGBoost, dan beberapa metode ensemble pada dataset DataCo Smart Supply Chain, untuk memprediksi keterlambatan dengan XGBoost sebagai model terbaik yang memperoleh Accuracy 89%, F1-score 89%, dan R^2 sebesar 0,70. Vatsal (2024) melakukan penelitian dengan target yang sama Late_risk_delivery menggunakan algoritma Logistic Regression, Random Forest dan XGBoost dan menghasilkan akurasi Random Forest 67% (ROC-AUC=73%), Logistic Regression dan XGBoost 69% (ROC-AUC=74%).

Berdasarkan penelitian terdahulu, Keenam penelitian tersebut tidak seluruhnya menggunakan fitur target yang sama. Sebagian besar memakai target Delivery Status, to predict transportation process stages. Penelitian ini menunjukkan bahwa algoritma berbasis ensemble seperti Random Forest dan XGBoost secara konsisten lebih unggul dibandingkan model linear seperti Logistic Regression. Penelitian ini melanjutkan pendekatan tersebut dengan membandingkan ketiga algoritma pada dataset DataCo Smart Supply Chain, disertai SMOTE, ensemble voting, dan cross validation untuk memastikan hasil evaluasi lebih stabil dan tidak bias.

BAB II

PEMBANGUNAN MODEL

2.1 Algoritma Logistic Regression




Model ini digunakan untuk klasifikasi biner untuk memprediksi risiko keterlambatan pengiriman. Algoritma ini saya pilih karena mampu menghasilkan probabilitas suatu data ke dalam kelas tertentu. Penelitian ini menggunakan proses hyperparameter tuning menggunakan GridSearchCV dengan 5-fold cross validation dengan metrik roc-auc untuk memperoleh kombinasi terbaik.

```
param_lr = {  
    'C': [0.01, 0.1, 1, 10, 100],  
    'solver': ['lbfgs'],  
    'penalty': ['l2'],  
    'class_weight': [None, 'balanced']  
}
```

LR - Best Parameter: {'C': 0.01, 'class_weight': 'balanced', 'penalty': 'l2', 'solver': 'lbfgs'}

Classification Report				
	precision	recall	f1-score	support
0	0.61	0.85	0.71	3614
1	0.82	0.56	0.66	4386
accuracy			0.69	8000
macro avg	0.72	0.70	0.69	8000
weighted avg	0.73	0.69	0.69	8000

Training Accuracy : 68.36%
Testing Accuracy : 68.95%
Gap : -0.59%



Hasil akurasi dengan parameter terbaik ini menunjukkan skor akurasi 69%. Berdasarkan confusion matrix model berhasil menemukan 3.067 kelas tidak terlambat TN dan kelas terlambat 2.449 TP. Tapi masih terdapat 547 data yang seharusnya diprediksi tidak terlambat diprediksi menjadi terlambat FP. Terdapat 1.937 data yang seharusnya diprediksi terlambat menjadi tidak terlambat FN. Pada selisih gap akurasi training dan testing juga menunjukkan bahwa model menunjukkan tidak ada indikasi overfitting ataupun underfitting.

Berdasarkan classification report di kelas tidak terlambat (0) diperoleh precision 61% dan recall sebesar 0,85% dan di kelas terlambat (1) diperoleh nilai precision lebih tinggi, yaitu 82% dan recall 56%. Recall tersebut artinya model mampu mengenali sebagian besar pengiriman yang tidak terlambat, recall yang relatif rendah model berarti belum berhasil mendeteksi kelas yang sebenarnya terlambat.


Berdasarkan grafik histogram, sebagian besar hasil prediksi memiliki nilai probabilitas yang tidak berada di sekitar batas keputusan 0,5, sehingga model relatif yakin dalam menentukan kelas setiap data. Kurva sigmoid menunjukkan proses perubahan nilai linear menjadi probabilitas antara 0 dan 1. Pada penelitian ini digunakan *threshold* sebesar 0,5 sebagai batas klasifikasi, yaitu probabilitas $\geq 0,5$ dikategorikan sebagai terlambat (1), sedangkan probabilitas $< 0,5$ dikategorikan sebagai tidak terlambat (0).

2.2 Algoritma Random Forest

Algoritma Random Forest digunakan untuk mengatasi keterbatasan model linear dengan memanfaatkan kumpulan decision tree (*ensemble learning*) berbasis bagging yang dapat menganalisis korelasi non-linear. Hyperparamater tuning menggunakan RandomizedSearchCV. Dengan 5-fold cross validation untuk memperoleh nilai terbaik berdasarkan nilai roc-auc.

```
param_rf = {  
    'n_estimators': [100, 200],  
    'max_depth': [8, 12, 16],  
    'min_samples_split': [20, 40, 60],  
    'min_samples_leaf': [10, 20, 30]  
}
```

RF - Best Parameter: {'n_estimators': 200, 'min_samples_split': 20, 'min_samples_leaf': 10, 'max_depth': 12}



Hasil akurasi dengan parameter terbaik ini menunjukkan skor akurasi 72%. Berdasarkan confusion matrix model berhasil menemukan 3.239 kelas tidak terlambat TN dan kelas terlambat 1.895 TP. Tapi masih terdapat 375 data yang seharusnya diprediksi tidak terlambat diprediksi menjadi terlambat FP. Terdapat 2.491 data yang seharusnya diprediksi tidak terlambat menjadi terlambat FN. Pada Training Accuracy 72,90% dan Testing Accuracy 71,62% (Gap 1,27%).

Berdasarkan classification report di kelas tidak terlambat (0) diperoleh precision 63% (+2%) lebih tinggi dari precision logistic regression dan recall sebesar 0,90% (+5%) dan di kelas terlambat (1) diperoleh nilai precision lebih tinggi, yaitu 87% (+5%) dan recall 57% (+1%). Recall tersebut artinya model mampu mengenali sebagian besar pengiriman yang tidak terlambat, recall yang relatif rendah model berarti belum berhasil mendeteksi kelas yang sebenarnya terlambat.

Pada Visualisasi RF hanya menampilkan satu pohon dari keseluruhan yang membentuk pohon Random Forest, fitur yang digunakan untuk root node adalah Market. Kemudian dilakukan pembagian internal node sampai leaf node. Namun fitur market ini tidak

dapat dianggap sebagai fitur yang paling berpengaruh secara keseluruhan, maka dari itu dilakukan peningkatan model yang akan dibahas di bab 3.

2.3 Algoritma XGboost


Pemilihan algoritma ini digunakan sebagai model ensemble berbasis gradien boosting yang dikenal memiliki performa unggul. Model ini membangun pohon keputusan yang kemudian dianalisis, diperbaiki kesalahan model sebelumnya sehingga mampu menghasilkan prediksi yang lebih akurat. Hyperparameter Tuning yang digunakan adalah RandomizedSearchCV dengan 5-fold cross validation untuk memperoleh nilai terbaik berdasarkan nilai roc-auc.

```
param_xgb = {
    'n_estimators': [200, 300, 500],
    'learning_rate': [0.03, 0.05, 0.1],
    'max_depth': [3, 4, 5],
    'min_child_weight': [5, 7, 10],
    'subsample': [0.7, 0.8, 0.9],
    'colsample_bytree': [0.7, 0.8, 0.9],
    'gamma': [0, 0.1, 0.3],
    'reg_alpha': [0, 0.1, 0.5],
    'reg_lambda': [1, 3, 5]
}
```

XGB - Best Parameter: {'subsample': 0.9, 'reg_lambda': 1, 'reg_alpha': 0.5, 'n_estimators': 500, 'min_child_weight': 5, 'max_depth': 5, 'learning_rate': 0.05, 'gamma': 0, 'colsample_bytree': 0.8}

	precision	recall	f1-score	support
0	0.64	0.85	0.73	3614
1	0.83	0.60	0.70	4386
accuracy			0.71	8000
macro avg	0.73	0.73	0.71	8000
weighted avg	0.74	0.71	0.71	8000


Training Accuracy : 76.34%
Testing Accuracy : 71.49%
Gap : 4.85%



Hasil akurasi dengan parameter terbaik ini menunjukkan skor akurasi 71%. Berdasarkan confusion matrix model berhasil menemukan 3.075 kelas tidak terlambat TN dan kelas terlambat 2.644 TP. Tapi masih terdapat 539 data yang seharusnya diprediksi tidak terlambat diprediksi menjadi terlambat FP. Terdapat 1742 data yang seharusnya diprediksi terlambat menjadi tidak terlambat FN. Pada Training Accuracy 76,34% dan Testing Accuracy 71,49% (Gap 4.85%).


2.4 ROC-AUC Curve, Precision-Recall Curve, Learning Curve dan, Validation Curve

2.4.1 ROC-AUC Curve




Berdasarkan kurva ROC-AUC ketiga model memiliki performa cukup baik karena keseluruhan kurva berada diatas garis acak. Model yang paling baik diantara ketiga model adalah XGBoost yang memiliki nilai ROC-AUC = 78,9% sedikit lebih unggul (0,3) dibandingkan Random Forest (78,7%), sedangkan Logistic Regression hanya (73,3%).

2.4.2 Precision-Recall Curve




Grafik ini digunakan untuk mengevaluasi model dalam mendeteksi kelas positif. Berdasarkan grafik diatas XGBoost memberikan performa terbaik dengan nilai AP = 85%, kemudian Random Forest (84,8%) yang terakhir ada Logistic Regression yang memperoleh nilai auc (79,8%). XgBoost memiliki kemampuan terbaik dalam menjaga keseimbangan precision dan recall sehingga lebih efektif mendeteksi pesanan atau paket yang terlambat.

2.4.3 Learning Curve



Learning curve dibangun dengan 5-fold cross validation agar mampu memberikan evaluasi performa yang lebih stabil. Pada Logistic Regression kurva training dan validation jaraknya berdekatan dan stabil pada kisaran 68-70% menunjukkan tidak adanya indikasi overfitting. Kurva training pada Random Forest sedikit lebih tinggi dari kurva validation menunjukkan gap 1,27%. Sementara itu, pada XGBoost kurva training lebih tinggi daripada validation dengan gap sekitar 4,85% yang menunjukkan baik.

2.4.3 Validation Curve



Hasil tuning parameter C pada Logistic Regression menunjukkan tidak adanya perubahan signifikan terhadap kedua kurva. Ini artinya performa model ini relatif stabil terhadap rentang C yang diuji. Pada Random Forest semakin dalam max_depth yang diuji akurasi validasi cenderung stabil. Sementara itu, pada XGBoost ketika nilai max_depth makin besar akibatnya akurasi training terus meningkat dan akurasi validasi relatif stabil. Hal ini membuat gap terlihat lebih besar, namun performa model masih relatif stabil.

BAB III

ANALISIS DAN PENINGKATAN MODEL

3.1 Teknik Peningkatan Model


3.1.1 Hyperparamater Tuning


Teknik ini digunakan untuk menghasilkan performa terbaik model dan digunakan di semua algoritma. Logistic Regression menggunakan 5-fold CV dan GridSearchCV, Random Forest menggunakan RandomizedSearchCV dan $n_iter=15$, XGBoost juga menggunakan RandomizedSearchCV dengan $n_iter=50$.

Alasan Saya Menjadikan Model Tuning sebagai Model Final

Sebelum dilakukan hyperparameter tuning, model Random Forest baseline menunjukkan indikasi overfitting yang signifikan, dengan training accuracy mencapai 100% namun testing accuracy hanya 71,24% (gap 28,76%). Hal ini menunjukkan bahwa model baseline cenderung menghafal data latih tanpa mampu melakukan generalisasi dengan baik ke data baru. Setelah dilakukan hyperparameter tuning, gap tersebut berhasil ditekan secara drastis menjadi hanya 1,27%, tanpa mengorbankan performa testing accuracy (71,62%).

Berdasarkan temuan ini, seluruh evaluasi, analisis feature importance, dan perbandingan performa pada laporan ini menggunakan model hasil hyperparameter tuning untuk membandingkan performa seluruh algoritma setelah seluruhnya dioptimalkan menggunakan hyperparameter tuning sebagai model final, karena terbukti lebih stabil dan mampu melakukan generalisasi yang lebih baik dibandingkan model baseline. Selain itu, berdasarkan metrik evaluasi (accuracy, precision, recall, F1-score dan ROC-AUC), performa model hasil hyperparameter tuning tetap memberikan hasil kompetitif dengan kombinasi terbaik dibandingkan model baseline, walaupun tidak sepenuhnya metrik mengalami peningkatan.





3.1.2 Feature Selection

No	Selected Feature
0 1	Type
1 2	Days for shipment (scheduled)
2 3	Customer State
3 4	Department Name
4 5	Longitude
5 6	Order City
6 7	Order Country
7 8	Order Item Discount
8 9	Order Item Product Price
9 10	Order Item Quantity
10 11	Order Region
11 12	Order Status
12 13	Product Category Id
13 14	Product Name
14 15	Shipping Mode


```
Shape X_train : (32000, 15)
Shape X_test  : (8000, 15)
```


k = 10	ROC-AUC = 0.7692
k = 15	ROC-AUC = 0.7909
k = 17	ROC-AUC = 0.7909
k = 20	ROC-AUC = 0.7909
k = 30	ROC-AUC = 0.7909
k = 31	ROC-AUC = 0.7909

Pada fitur seleksi ini digunakan untuk melihat fitur mana yang paling baik dan optimal. Dengan menggunakan SelectKBest dan f_classif skor ANOVA F-value, saya menguji beberapa nilai k = 10, 15, 17, 20, 30, 31 hasil menunjukkan bahwa nilai ROC-AUC stabil pada k=15..

3.1.3 SMOTE (Synthetic Minority Oversampling Technique)

Teknik ini digunakan karena sebelumnya memiliki indikasi ketidakseimbangan kelas dari (1=terlambat)17.546:14.454(0=tidak terlambat) menjadi 17.546:17.546. Pada algoritma Logistic Regression tidak diimplementasikan SMOTE karena sudah ditangani dengan `class_weight = balanced`.

Model	Akurasi sebelum SMOTE	Akurasi sesudah SMOTE
Random Forest	72%	72%
XGBoost	72%	71%

Accuracy Random Forest + SMOTE: 0.71925				
	precision	recall	f1-score	support
0	0.65	0.82	0.73	3614
1	0.81	0.64	0.71	4386
accuracy			0.72	8000
macro avg	0.73	0.73	0.72	8000
weighted avg	0.74	0.72	0.72	8000

	precision	recall	f1-score	support
0	0.63	0.90	0.74	3614
1	0.87	0.57	0.69	4386
accuracy			0.72	8000
macro avg	0.75	0.73	0.71	8000
weighted avg	0.76	0.72	0.71	8000

Accuracy XGBoost + SMOTE: 0.716625				
	precision	recall	f1-score	support
0	0.64	0.88	0.74	3614
1	0.85	0.59	0.69	4386
accuracy			0.72	8000
macro avg	0.74	0.73	0.72	8000
weighted avg	0.75	0.72	0.71	8000

	precision	recall	f1-score	support
0	0.64	0.85	0.73	3614
1	0.83	0.60	0.70	4386
accuracy			0.71	8000
macro avg	0.73	0.73	0.71	8000
weighted avg	0.74	0.71	0.71	8000

Bisa disimpulkan bahwa dengan teknik ini akurasi mengalami perubahan walaupun hanya naik sedikit, pada Random Forest akurasi naik 72% (+1) sementara pada XGBoost (-1%) . Pada Random Forest recall kelas 0 turun -8 %. Recall kelas 1 naik +7%, XGBoost presisi kelas 1 naik +2% recall kelas 0 naik +3% dan recall kelas 0 turun -1%. SMOTE tidak memberikan perubahan yang besar karena data uji cukup imbang (45:55).

3.3 Ensemble (Voting Classifier)


Teknik ini menggabungkan prediksi algoritma LR, RF dan XGB, Serta RF dan XGB. Hasil LR+RF+XGB menunjukkan akurasi sebesar 71%. Hasil RF+XGB akurasi 72% artinya RF+XGB terbukti efektif dibanding LR karena LR lemah mengatasi hubungan fitur kompleks non-linear. Namun ensemble ini belum memberikan peningkatan yang signifikan karena model telah dioptimasi dengan baik melalui hyperparameter tuning.

Accuracy Voting Ensemble: 0.714375					
	precision	recall	f1-score	support	
0	0.63	0.87	0.73	3614	
1	0.84	0.59	0.69	4386	
accuracy			0.71	8000	
macro avg	0.74	0.73	0.71	8000	
weighted avg	0.75	0.71	0.71	8000	

Accuracy Voting (RF + XGBoost): 0.71675					
	precision	recall	f1-score	support	
0	0.63	0.89	0.74	3614	
1	0.86	0.58	0.69	4386	
accuracy			0.72	8000	
macro avg	0.75	0.73	0.71	8000	
weighted avg	0.76	0.72	0.71	8000	


3.4 Cross Validation (Stratified K-Fold)

Teknik ini sudah diterapkan ke seluruh algoritma untuk menentukan performa terbaik, stabil dan, tidak bias. Hasil menunjukkan bahwa XGBoost yang paling unggul dari kedua ROC-AUC CV (78,2%) dan ROC-AUC (78,9%). Dengan selisih 0,7 ini model stabil dan tidak overfitting.




3.3 Feature Importance


3.3.1 Feature Importance Logistic Regression




3.3.2 Feature Importance Random Forest



3.3.3 Feature Importance XGBoost



3.3 Perbandingan Performa Model



Berdasarkan gambar diatas, disimpulkan XGBoost menjadi model terbaik karena recall nya lebih unggul dibandingkan ke-2 algoritma. Dilihat dari akurasi RF (71,63%) dan XGBoost (71,49%) RF memang lebih unggul selisih (0,14), tapi pada penelitian saya ini yang menekankan Terlambat atau Tidak Terlambat dibutuhkan recall tertinggi dari ketiga algoritma tersebut agar model mampu menentukan ketepatan prediksi dan mendeteksi yang sebenarnya kelas positif.

BAB IV

PEMBAHASAN DAN KESIMPULAN

4.1 Intepretasi Model

Berdasarkan hasil *feature importance* pada ketiga algoritma, variabel yang paling berpengaruh terhadap risiko keterlambatan pengiriman adalah Shipping Mode dan Days for Shipment (scheduled). Hal ini konsisten dengan hasil EDA pada Bab I, di mana mode pengiriman First Class dan Second Class justru memiliki tingkat keterlambatan yang jauh lebih tinggi (95,3% dan 76,6%) dibandingkan Same Day dan Standard Class (45,7% dan 38,1%), yang mengindikasikan adanya inkonsistensi layanan pada mode pengiriman tertentu. Selain itu, jadwal pengiriman yang lebih singkat (median 2 hari pada pesanan terlambat) juga terbukti berasosiasi dengan risiko keterlambatan yang lebih tinggi.

Secara bisnis, temuan ini mengindikasikan bahwa keterlambatan bukan semata-mata disebabkan oleh faktor eksternal (wilayah, produk), melainkan lebih banyak dipengaruhi oleh kebijakan operasional internal, yaitu pemilihan mode pengiriman dan estimasi jadwal yang diberikan kepada pelanggan.

4.2 Algoritma Terbaik

Algoritma XGBoost dipilih sebagai model terbaik dalam penelitian ini. Meskipun secara akurasi Random Forest sedikit lebih unggul (71,63% vs 71,49%), pemilihan ini didasarkan pada pertimbangan bahwa metrik recall lebih relevan untuk konteks permasalahan yang diangkat. Kesalahan model dalam bentuk *false negative* (memprediksi pesanan tidak terlambat padahal sebenarnya terlambat) berdampak lebih besar bagi perusahaan dibandingkan *false positive*, karena keterlambatan yang tidak terdeteksi berarti perusahaan kehilangan kesempatan melakukan mitigasi lebih awal. XGBoost mencatat recall tertinggi (60,3%), F1-score tertinggi (70,9%), ROC-AUC CV tertinggi (78,2%) serta ROC-AUC tertinggi (78,9%), dibandingkan Random Forest dan Logistic Regression, sehingga dinilai paling seimbang dalam mendeteksi kelas positif tanpa mengorbankan presisi secara signifikan.

4.3 Kekuatan dan Kelemahan Model

4.3.1 Kekuatan Model

Mampu menangani hubungan non-linear antar fitur, tidak seperti Logistic Regression. Recall dan F1-score tertinggi di antara ketiga model, sehingga lebih andal mendeteksi pesanan berisiko terlambat. Hasil cross validation (ROC-AUC CV = 78,2%) menunjukkan performa yang stabil dan konsisten dengan hasil evaluasi pada data uji tunggal (ROC-AUC = 78,9%), sehingga model tidak overfitting terhadap satu pembagian data tertentu.

4.3.2 Kelemahan Model

Berdasarkan learning curve, XGBoost menunjukkan gap 4,8% (baik) antara kurva training dan validation, gap ini lebih besar dibandingkan Random Forest (gap 1,27% dan Logistic Regression (gap minimal -0,59%). Precision kelas terlambat (1) masih di bawah

Random Forest, artinya XGBoost sedikit lebih sering memprediksi pesanan sebagai "terlambat" padahal sebenarnya tidak.

4.4 Rekomendasi Implementasi

1. Perusahaan disarankan mengevaluasi ulang SLA (*Service Level Agreement*) pada mode pengiriman First Class dan Second Class, mengingat tingkat keterlambatannya jauh lebih tinggi dibanding model lain.
2. Model XGBoost dapat diintegrasikan ke sistem operasional untuk memberikan *early warning* terhadap pesanan yang berisiko terlambat, sehingga tim logistik dapat melakukan mitigasi (misal realokasi kurir, komunikasi proaktif ke pelanggan) sebelum keterlambatan benar-benar terjadi.
3. Untuk pengembangan lanjutan, penelitian dapat mengeksplorasi fitur tambahan seperti data historis performa kurir per wilayah yang belum tersedia di dataset ini.

4.5 Kesimpulan

1. Berhasil membangun model klasifikasi untuk memprediksi risiko keterlambatan pengiriman paket menggunakan algoritma Logistic Regression, Random Forest, dan XGBoost pada dataset DataCo Smart Supply Chain melalui tahapan preprocessing, feature engineering, feature selection, hyperparameter tuning, dan evaluasi model.
2. Hasil perbandingan menunjukkan bahwa XGBoost menjadi model terbaik karena memiliki recall, F1-score, dan ROC-AUC dan ROC-AUC CV tertinggi, sehingga lebih efektif dalam mendeteksi pesanan yang berisiko terlambat dibandingkan Logistic Regression dan Random Forest. Hasil penelitian ini juga konsisten dengan penelitian Vatsal (2024) yang menggunakan target *Late_delivery_risk* dengan perbedaan yang tidak terlalu jauh dengan hasil penelitian saya.
3. Penerapan SMOTE dan Voting Classifier belum memberikan peningkatan performa yang signifikan. Hal ini menunjukkan bahwa model dasar yang telah dioptimasi melalui hyperparameter tuning sudah mampu memberikan hasil yang baik.
4. Berdasarkan hasil feature importance, Shipping Mode dan Days for Shipment (scheduled) merupakan faktor yang paling berpengaruh terhadap risiko keterlambatan pengiriman, sehingga dapat menjadi dasar bagi perusahaan dalam melakukan evaluasi proses pengiriman.
5. Logistic Regression memiliki interpretasi yang sederhana dan stabil, namun kurang mampu menangkap hubungan non-linear sehingga performanya paling rendah. Random Forest memberikan akurasi yang baik dan relatif stabil, tetapi kemampuan mendeteksi kelas terlambat masih di bawah XGBoost. XGBoost menghasilkan performa terbaik, namun model ini lebih kompleks, membutuhkan waktu pelatihan lebih lama.

DAFTAR PUSTAKA

- Apnena, R. D., Ginting, G., Sudrajat, A., & Islam, H. M. M. (2025). *Comparative analysis of supervised learning algorithms for delivery status prediction in big data supply chain management*. *Jurnal Teknik Informatika (JUTIF)*, 6(3), 1443–1456. <https://doi.org/10.52436/1.jutif.2025.6.3.4689>
- Eriya, E., Widodo, C. E., & Nugraheni, D. M. K. (2026). *Perbandingan model machine learning berbasis BADIR framework untuk deteksi fraud dan prediksi keterlambatan pengiriman pada supply chain*. *Simetris: Jurnal Teknik Mesin, Industri, Elektro dan Ilmu Komputer*, 17(1), 219–232. <https://doi.org/10.24176/simet.v17i1.16307>
- Gunawan, N. D., Beng, J. T., Perdana, N. J., Francesco, D., & Matthew, D. (2025). *Klasifikasi kinerja pengiriman logistik berbasis prediksi ETA menggunakan machine learning di PT. De Besta Trans*. *INTECOMS: Journal of Information Technology and Computer Science*, 8(6), 2108–2119. <https://doi.org/10.31539/gpwqvh82>
- Pambudi, H. K., Kusuma, P. G. A., Yulianti, F., & Julian, K. A. (2020). *Prediksi status pengiriman barang menggunakan metode machine learning*. *Jurnal Ilmiah Teknologi Informasi Terapan*, 6(2), 100–109. <https://doi.org/10.33197/jitter.vol6.iss2.2020.396>
- Sultana, N., Moosa, A. M., Faisal, S. M. F., & Chowdhury, T. N. (2025). *Machine learning models for optimizing online order fulfillment: Forecasting lead time and late delivery risk*. *Journal of Optimization and Supply Chain Management*, 2(2), 70–81. <https://doi.org/10.22034/ISS.2025.9373.1049>

c7746b742b0ab330_uas-ml

ORIGINALITY REPORT

5%

SIMILARITY INDEX

PRIMARY SOURCES

- | | | |
|---|---|-----------------|
| 1 | www.coursehero.com
Internet | 40 words — 1% |
| 2 | Evgenii A. Pustozarov, Aleksandra S. Tkachuk, Elena A. Vasukova, Anna D. Anopova et al. "Machine Learning Approach for Postprandial Blood Glucose Prediction in Gestational Diabetes Mellitus", <i>IEEE Access</i> , 2020
Crossref | 23 words — < 1% |
| 3 | jurnal.polibatam.ac.id
Internet | 18 words — < 1% |